Agentic On-Policy Distillation 发展脉络（2026.10）

> **On-Policy Distillation（OPD）前置文章阅读：**
>
> - On-Policy Distillation（OPD）系列文章总结：On-Policy Distillation（OPD）系列文章总结
> - OPD 里程碑工作总结：On-Policy Distillation 是什么？工作脉络梳理
> - OPD 开源项目推荐：2026 年 On-Policy Distillation 开源项目总结

本期总结 OPD 在 multi-turn long-horizon agent（Agentic On-Policy Distillation）场景的工作脉络。

single-turn OPD 方法拓展到 multi-turn 场景（Agentic）会导致 OPD 依赖的三个假设不成立：

1. 监督单位与信用单位重合。
2. teacher 在 student 到达的状态上有定义。
3. 稠密的 teacher-student 对数概率比可以作为价值估计。

现有的 Agentic On-Policy Distillation 方法可以按要解决的问题分成四条线：

1. **监督粒度与信用分配的错位（supervision-credit granularity mismatch）**：对应假设 1 的失效。SOD（step-level 调节蒸馏强度）、StepOPSD（把 step 作为单位做信用再分配）、TurnOPD（预算/损失按 turn 重新分配）。
2. **状态分布偏移（covariate shift）**：对应假设 2 的失效。Revisiting DAgger（turn-level 师生插值采样）、Guided-OPD（课程调度 Teacher 干预概率）、SAGE-OPD（Teacher 自决策的选择性干预）、ReOPD（可靠性感知的前缀分布）。
3. **特权信息不对称（information asymmetry）**：对应假设 2 的失效，本质是 OPSD 类方法在 multi-turn 场景下额外暴露的问题：teacher 带着 student 不可见的特权信息，给出的分布未必是 student 能到达的。Skill-SD（把轨迹提炼成 skill 作为特权信息）、AR-OPD（只对齐局部可达的部分）、HERO（把终局反馈拆成 turn-level 的观测诊断）。
4. **时序信用分配（temporal credit assignment）**：对应假设 3 的失效。OPPO（token-level 的贝叶斯值递归）、PBSD（turn-level 的贝叶斯证据分解）、AgentOPSD（递归信念与边际修正）、CrEST 与 TASPO（Teacher 只作用于更新幅度）。

> 推荐阅读综述：《A Survey of On-Policy Distillation for Large Language Models》
>
> 工作梳理仓库：Awesome-LLM-On-Policy-Distillation
>
> Agentic RL 背景参考：2026 Agentic RL 开源工作总结（代码开源）

1. 背景：single-turn OPD 的三个隐含假设

single-turn OPD 的目标函数是在 student 自采样的序列上 token-level 对齐师生分布，成立的前提隐含三个假设：

- **监督单位与信用单位重合**：单轮推理中，单个 token 就是单次决策，因此 token-level 的 KL 就是逐决策的监督。但是在多轮 agent 场景下，决策单位是动作（Action）或工具调用（Tool Use），单个 Turn 包含的上百个 token 里决定成败的往往只有工具名与参数几个位置，其余是对观测（Observation）的复述。因此在多轮 agent 场景下，single-turn OPD 的 token-level KL 均匀地把监督信号铺开在了与决策无关的位置。
- **teacher 在 student 到达的状态上有定义**：单轮推理中，teacher / student 面对同一个 prompt，分布偏移只来自 student 的采样。在多轮 agent 场景下，student 的采样分布偏移会导致环境返回的观测完全不同，进而加剧分布偏移，甚至到达 teacher 从未见过的状态（在这些状态上 teacher 未必能给出比 student 更好的分布）。
- **稠密的 teacher-student 对数概率比可以作为价值估计**：OPD 相比 Agentic RL 最大的优势是能提供稠密信号，缓解轨迹级稀疏奖励在信用分配上的问题（具体细节参考 面试官：Agentic RL 场景下如何设计过程奖励（Process Reward）？Token-Level 优势如何计算？）。但 teacher-student 的对数概率比本质是衡量模仿程度，不是价值估计，直接把对数概率比作为稠密奖励只能鼓励模仿接近而非任务完成。

2. 监督粒度与信用分配的错位（supervision-credit granularity mismatch）

SOD：step-level 调节蒸馏强度

> 把 OPD 用到工具集成推理（Tool-Integrated Reasoning, TIR），会出现 teacher 的可靠性沿 step 下降的问题。

动机：OPD 的目标函数默认 teacher 的监督在 student 访问到的所有状态上可靠，这个假设要求分布漂移是渐进的，而 TIR 里工具观测带来的状态转移是不连续的，某次错误的工具调用会造成后续所有推理步 teacher-student 分歧逐步放大，teacher 的 token-level 监督越往后越不可信。

论文给出的可观测代理是 step 级失配，把一个 step 内所有 token 的 teacher-student KL 取平均：

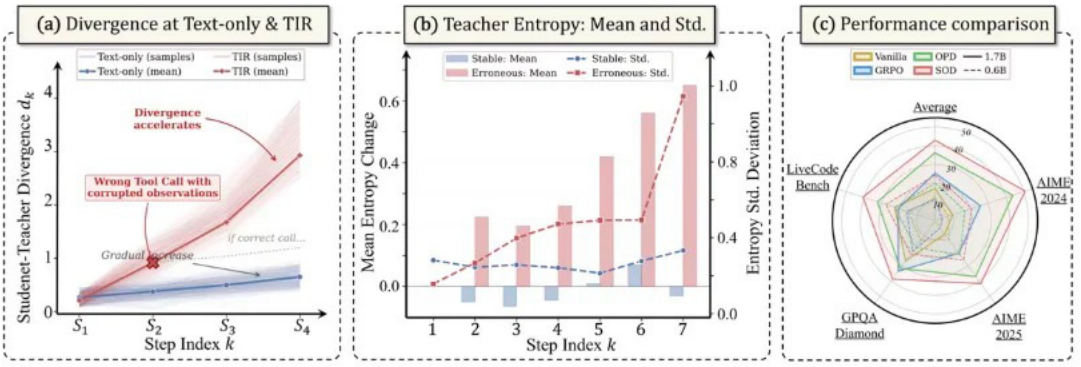
$$\Delta_k = \frac{1}{|I_k|} \sum_{t \in I_k} D_{\mathrm{KL}}\left(\pi_\theta(\cdot \mid y_{<t}) \,\|\, \pi_{\text{teacher}}(\cdot \mid y_{<t})\right)$$

- I_k 是第 k 个 step 所覆盖的 token 集合，对应步骤内完整的推理（Reasoning）加工具调用（Tool Use）。
- Δ_k 越大说明 student 在这步已经走到 teacher 不熟悉的区域，此处的 teacher 概率不再是更好的答案。

实现：按 Δ_k 给每个 step 的蒸馏项配一个权重 w_k，高分歧处衰减、对齐良好处保留稠密引导：

$$w_k = \min\left(\prod_{u=1}^{k-1} \frac{d_u + \epsilon}{d_{u+1} + \epsilon},\, 1+\delta\right), \qquad w_1 = 1$$

- d_u 是第 u 个 step 内 teacher-student 对数概率差绝对值的均值，可以看作 Δ_k 的估计（两者正相关，但不是严格单调关系），ϵ 为稳定常数 10^{-6}。
- 连乘可以逐项约掉：$w_k = \min\left(\frac{d_1 + \epsilon}{d_k + \epsilon},\, 1+\delta\right)$，即权重只取决于当前 step 的分歧相对第 1 个 step 的比例，与中间各 step 无关。当前 step 分歧比起点大时权重小于 1，student 恢复对齐后权重回升；上界 $1+\delta$（实现取 $\delta = 0.2$）防止个别 step 主导梯度。



TIR 与纯文本下 teacher-student 分歧沿 step 的对比、teacher 熵的均值与标准差

左上图是纯文本与 TIR 两种设定的 teacher-student 分歧沿 step 变化：纯文本全程平缓，TIR 在工具返回之后出现明显抬升，这是不连续转移的直接证据。

StepOPSD：把 step 作为单位做信用再分配

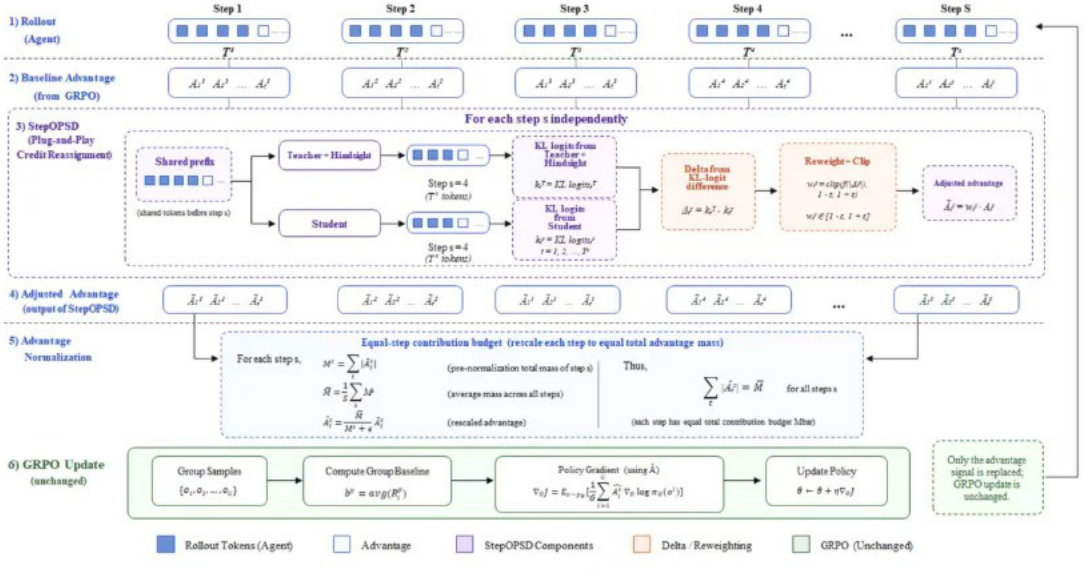
SOD 给出 step-level 蒸馏强度，StepOPSD 把 step 作为信用分配的基本单位。

动机：(同 SOD) 现有 OPD 把异质的 Agent 轨迹当作单体字符串处理，奖励是稀疏的轨迹级信号，但是 Agent 任务的成败却往往取决于少数局部决策，token-level 监督与 turn-level 因果之间缺少中间结构。

实现：把轨迹拆成以动作为中心的 step 片段，把 token-level 对数概率差折算成保号的优势重塑（sign-preserving advantage reshaping），并对每个 step 施加归一化的信用预算，最后进入 GRPO 更新：

$$\tilde{A}_\ell = (1-\lambda_{\text{mix}})A_\ell + \lambda_{\text{mix}}\, w_\ell A_\ell, \qquad w_\ell = \text{clip}\left(2\sigma\left(\text{sign}(A_\ell)\,\Delta_\ell\right),\, 1-\alpha_{\text{clip}},\, 1+\alpha_{\text{clip}}\right)$$

- Δ_ℓ 是第 ℓ 个 token 的 teacher-student 对数概率差，teacher 的上下文在 student 的因果前缀之外拼接同一 GRPO 组内的首条成功轨迹作为 hindsight（OPSD），π_T 取冻结~10 步的旧参考策略以避免不稳定。
- A_ℓ 是 GRPO 给出的 token-level 优势，w_ℓ 落在 $(0, 2)$，$\lambda_{\text{mix}} \in [0, 1)$，乘子 $1-\lambda_{\text{mix}}+\lambda_{\text{mix}}w_\ell$ 恒正，$\tilde{A}_\ell$ 与 A_ℓ 严格同号（sign-preserving），重塑只改变绝对大小。
- 每个 step 内的重塑权重再做归一化，使各 step 分到相同的总绝对修改预算（而非逐 token 的平均预算，否则 token 多的 step 总修改量仍然更大），防止冗长的 step 独占梯度。



StepOPSD 的 step 切分、重打分与优势重塑流程

保号（sign-preserving）是 StepOPSD 的关键约束：重塑只改变优势的大小，不改变它的符号，所以轨迹级的对错判断仍然由可验证奖励决定，蒸馏只在同号的前提下把权重集中到关键 step 上。

TurnOPD：预算/损失按 turn 重新分配

> SOD 与 StepOPSD 关注的是监督权重，TurnOPD 关注算力预算。

动机：vanilla agent OPD 有两个低效问题：

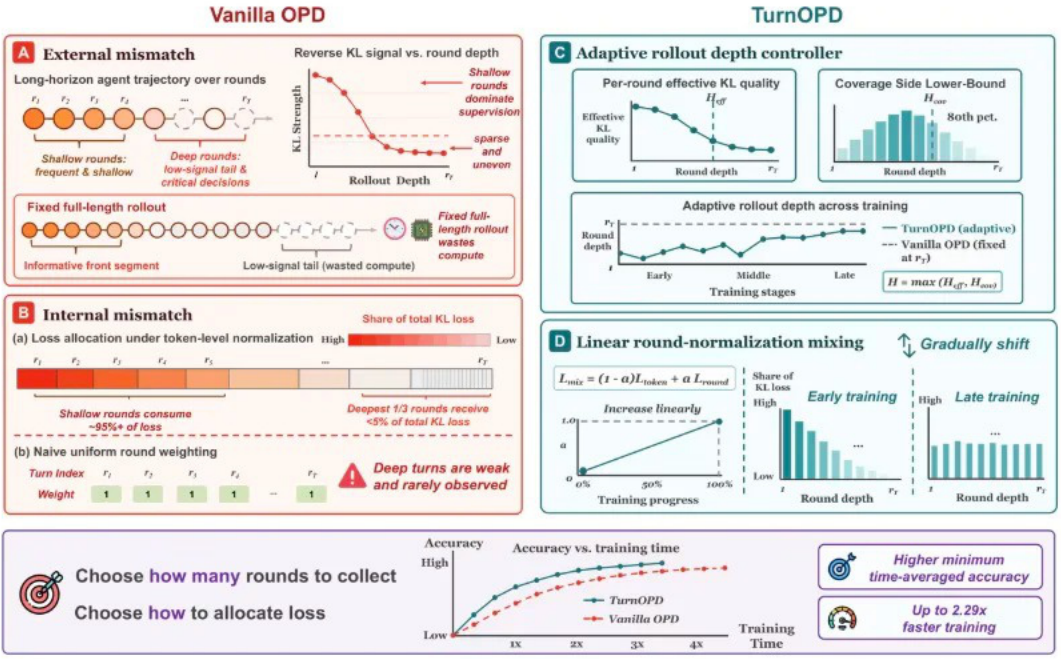
- 整段 rollout 把大量时间花在长尾 turn，而这些 turn 提供的 KL 监督噪声大。
- 轨迹级的 KL 目标把大部分损失集中在前期 turn 的 token 上，后期 turn 的决策 token 反而训练不足。

实现：分别构造两个预算控制器，

- 自适应 rollout 深度预算（adaptive rollout-depth budget）用探针式的 turn 统计决定采样深度。
- 渐进归一化损失预算（progressive turn-normalized loss budget）把 KL 权重从 token-level 移向 turn 均衡：

$$\mathcal{L}_{\text{mix}} = (1-\alpha)\,\mathcal{L}_{\text{token}} + \alpha\,\mathcal{L}_{\text{round}}$$

- $\mathcal{L}_{\text{token}}$ 是按 token 数归一化的常规 KL 损失，长 turn 因此占更大权重。
- $\mathcal{L}_{\text{round}}$ 是按 turn 归一化的 KL 损失，每个 turn 不论长短都获得相同权重。
- α 从 0 线性升到 1，训练早期让长 turn 主导以先把基本行为对齐，后期转向 turn 均衡以补后期 turn 的决策。



vanilla OPD 的两处低效与 TurnOPD 的两个预算控制器

3. 状态分布偏移（covariate shift）

Revisiting DAgger：turn-level 师生插值采样

> 既然 teacher 在学生独自采样的状态上不可靠，就让 teacher 参与采样。

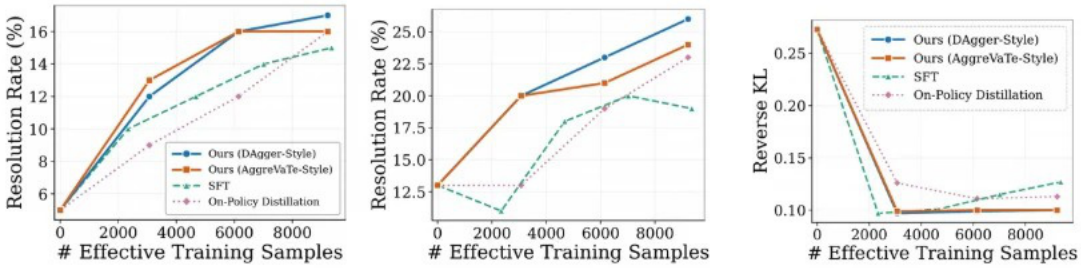
动机：监督微调（蒸馏）有稠密的 teacher 监督，但训练在离线的 teacher 轨迹上，推理部署时存在协变量偏移（covariate shift）问题。可验证奖励的强化学习（RLVR）根据 on-policy rollout 训练，没有这层偏移，但只有稀疏的结果奖励。

实现：把模仿学习里的 DAgger 重新用到多轮 Agent 场景。轨迹由师生策略在 turn-level 插值（turn-level interpolation）共同采样，student 在这些轨迹上用 teacher 的监督标签训练：

$$p_i^{\text{turn}}(b_{1:T_{\max}}) = \prod_{t=1}^{T_{\max}} \beta_i^{b_t}(1-\beta_i)^{1-b_t}, \qquad p_i^{\text{traj}}(b_{1:T_{\max}} \mid \kappa) = \prod_{t=1}^{\kappa} \mathbb{I}\{b_t = 0\} \prod_{t=\kappa+1}^{T_{\max}} \mathbb{I}\{b_t = 1\}$$

- $b_t \in \{0,1\}$ 指示第 t 个 turn 由谁出动作，$b_t = 1$ 取 $a_t \sim \pi_e(\cdot \mid s_t)$ 即 teacher，$b_t = 0$ 即 student π_θ。
- β_i 是第 i 轮迭代的 teacher 占比，混合策略 $\mu_i = \beta_i \pi_e + (1-\beta_i)\pi_{\theta_i}$ 即 DAgger 原来的写法，β_i 衰减到 0 时采样分布收敛到 student。

- p^{turn} 让师生在同轨迹按 turn 独立抽签交替，p^{traj} 只在第 κ 个 turn 切换，前段为 student 后段为 teacher。



DAgger 训练与 SFT、OPD 在有效样本数下的解决率对比

Guided-OPD：课程调度 Teacher 干预概率

> Revisiting DAgger 与 Guided-OPD 都让 teacher 随训练逐步退出采样，区别在于：Revisiting DAgger 用统一的 token-level 监督训练 student，Guided-OPD 则按 turn 的来源切换散度方向（student 的 turn 用反向 KL，teacher 的 turn 用前向 KL），并显式设计了干预概率的课程。

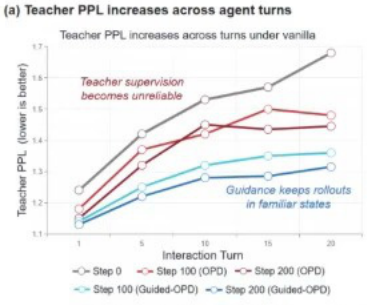
动机：student 的错误沿 turn 累计，轨迹逐渐偏移出 teacher 正确的状态分布，teacher 无法在 student 需要的位置给出可靠监督。

实现：在每条 rollout 内部混合 teacher 生成的 turn 与学生生成的 turn，并把 teacher 的干预概率按课程调度逐步衰减到接近零。早期强引导把轨迹留在 teacher 分布附近，随后逐步撤除，最终回到推理时实际使用的 on-policy 状态。

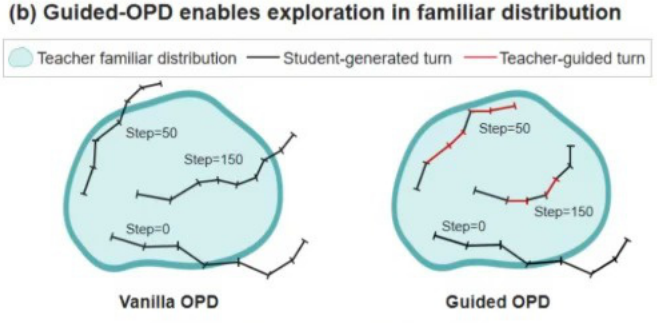
$$\mathcal{L}_{\text{Guided-OPD}}(\theta;t) = (1-\beta_t)\,\mathcal{J}^{\pi_\theta}_{\text{rKL}}(\theta) + \beta_t\,\mathcal{J}^{\pi_\phi}_{\text{fKL}}(\theta), \qquad \beta_t = \beta_{\text{start}}\left(\frac{\beta_{\text{end}}}{\beta_{\text{start}}}\right)^{\xi_t}$$

- π_ϕ 是 teacher，两个 $\mathcal{J}$ 项分别取在 student 出的 turn 与 teacher 出的 turn 上，学生的 turn 上用反向 KL $\mathcal{D}_{\text{KL}}(\pi_\theta\|\pi_\phi)$，teacher 的 turn 上用前向 KL $\mathcal{D}_{\text{KL}}(\pi_\phi\|\pi_\theta)$。
- β_t 是第 t 步的干预概率，$\xi_t \in [0,1]$ 是归一化的训练进度。上式的指数（几何）课程从 β_{start} 衰减到 β_{end}，要求 $\beta_{\text{end}} > 0$，若直接取 $\beta_{\text{end}} = 0$，只要 $\xi_t > 0$ 就有 $\beta_t = 0$，相当于第一步就撤掉 teacher。指数课程只是候选之一，论文默认用余弦课程，后者可以平滑地衰减到 0。
- $\beta_t \to 0$ 时整个目标退化成 on-policy 的反向 KL，与部署时的状态分布一致。

> **散度方向随动作切换的必要性**：teacher 的 turn 学生没有采样权，无法在自己的分布上取期望，只能用前向 KL 做模式覆盖。前缀来源与 KL 方向这一对取舍在单轮里已经被系统比较过，参考 面试官：OPD 算法中的正向 KL / 反向 KL 的区别？ 。



teacher 在学生轨迹上的困惑度随交互回合单调上升，而加了引导之后整条曲线被压平。



引导让探索保持在 teacher 熟悉的分布之内。

SAGE-OPD：Teacher 自决策的选择性干预

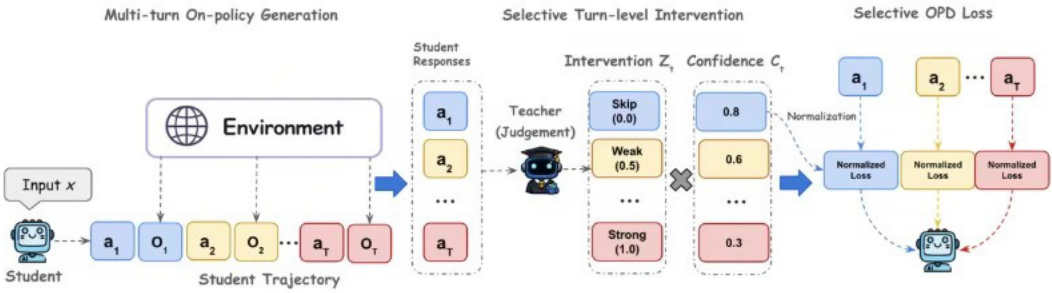
> Guided-OPD 按课程调度 teacher 干预强度，SAGE-OPD 按每个 turn 的实际情况判断。

动机：标准的稠密 token-level OPD 在多轮 Agent 场景不稳定，SAGE-OPD 列举了三种具体表现：过度惩罚语义上同样有效的替代动作、强化重复动作的局部退化、偏离分布上不可靠的 teacher 监督。

实现：不给所有 turn 施加同样的监督。先观察环境反馈，再用 teacher 判断决定当前这条 student 回复应当跳过还是介入，不引入验证器：

$$c_t(h_t,a_t) = \frac{1}{|a_t|}\sum_{i=1}^{|a_t|}\max_{v\in\mathcal{V}}\pi_\phi(v \mid h_t, a_{t,<i}), \qquad i_t(h_t,a_t) \in \{0,\alpha,1\}$$

- c_t 是 teacher 沿 student 动作 a_t 的前缀，在每个位置上对自己最可能 token 的预测概率的均值，取值范围 $[1/|\mathcal{V}|, 1]$。它衡量的是 teacher 在 student 到达的这个状态上的自信程度，与 student 实际选了哪个 token 无关。若要衡量 teacher 是否认可 a_t，应当用 $\pi_\phi(a_{t,i} \mid h_t, a_{t,<i})$。
- i_t 是干预强度，对应 Skip、Weak、Strong 三档，分别取 0、α 与 1，由环境反馈与 teacher 的判断（一条干预评估提示）共同决定，再与 c_t 相乘得到当前 turn 的最终权重。
- Skip 档把该 turn 的散度整项置零，即 teacher 的分布在这个状态上不可用。



按环境反馈与 teacher 判断决定跳过或介入的选择性流程

> DAgger 与 Guided-OPD 都在采样阶段让 teacher 接管若干个 turn，代价是每次都要执行 teacher 的生成，SAGE-OPD 把 teacher 的角色从生成改成判断，只在判定需要的 turn 产生干预成本。

ReOPD：可靠性感知的前缀分布

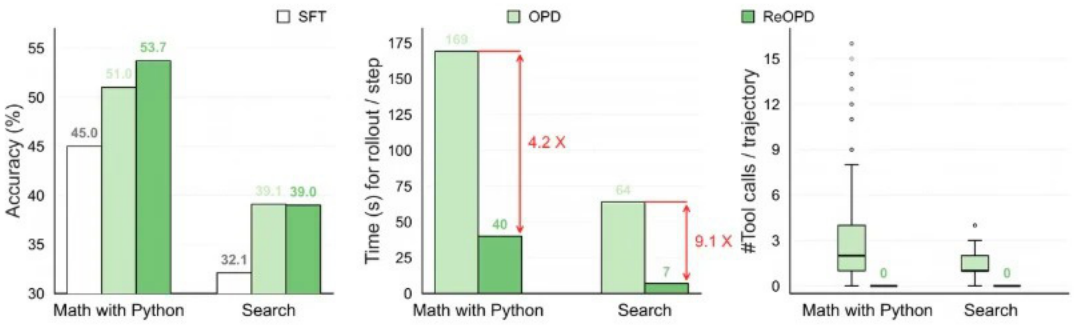
> ReOPD 从理论上解释 teacher 的介入强度 / on-policy 强度对 OPD 最终表现的影响。

动机：前缀 on-policy 提高了历史状态对 student 的相关性，但同时会使得 teacher 在不可信的历史上进行查询，这个现象称为前缀陷阱（prefix trap）。

实现：ReOPD 把多轮 OPD 目标与理想目标之间的差距界定义为学生占用失配（student-occupancy mismatch）与 teacher 不可靠程度两项之和。提高 on-policy 强度降低第一项但是却抬升第二项，因此存在一个 trade-off。因此 ReOPD 的做法不是把蒸馏改为完全 on-policy，而是采用可靠性感知的前缀分布设计（reliability-aware prefix design），在算法侧用按 step 衰减的采样调度来实现，偏向早期、偏移更小的前缀：

$$\rho_t^\star(h_t \mid x) \propto \left[d^t_{\theta_{\text{old}}}(h_t \mid x)\right]^{\gamma_t} \left[d^t_T(h_t \mid x)\right]^{1-\gamma_t}, \qquad \gamma_t = \frac{\lambda_{\text{stu},t}}{\lambda_{\text{stu},t} + \lambda_{\text{tea},t}}$$

- h_t 是第 t 个 turn 之前的全部观测与动作，$d^t_{\theta_{\text{old}}}$ 是 student 在第 t 步的历史占用分布，d^t_T 是 teacher 在第 t 步的历史占用分布，$\rho_t^\star$ 是实际用来采前缀的分布，x 为任务提示。
- $\lambda_{\text{stu},t}$ 与 $\lambda_{\text{tea},t}$ 分别是占用失配与 teacher 不可靠这两项的代价系数，γ_t 是相对权重。
- 若前缀从 teacher 占用 d^t_T 中采样，重要性权重为 $w_t = \rho_t^\star / d^t_T \propto \left(d^t_{\theta_{\text{old}}} / d^t_T\right)^{\gamma_t}$。若从 student 占用中采样，则为 $\left(d^t_T / d^t_{\theta_{\text{old}}}\right)^{1-\gamma_t}$。两种情况都只依赖两个占用分布的比值（环境转移项相互抵消，退化为逐步策略概率比的乘积），不需要显式建模 $\rho_t^\star$。



ReOPD 与 SFT、OPD 在准确率、每步耗时与工具调用次数上的对比

> **ReOPD 给出的结论**：teacher-student 差距大的时候，降低高偏移的后段步骤的权重更好。这也解释了 TurnOPD 截断尾部回合为什么有效。

4. 特权信息不对称（information asymmetry）

Skill-SD：把轨迹提炼成 skill 作为特权信息

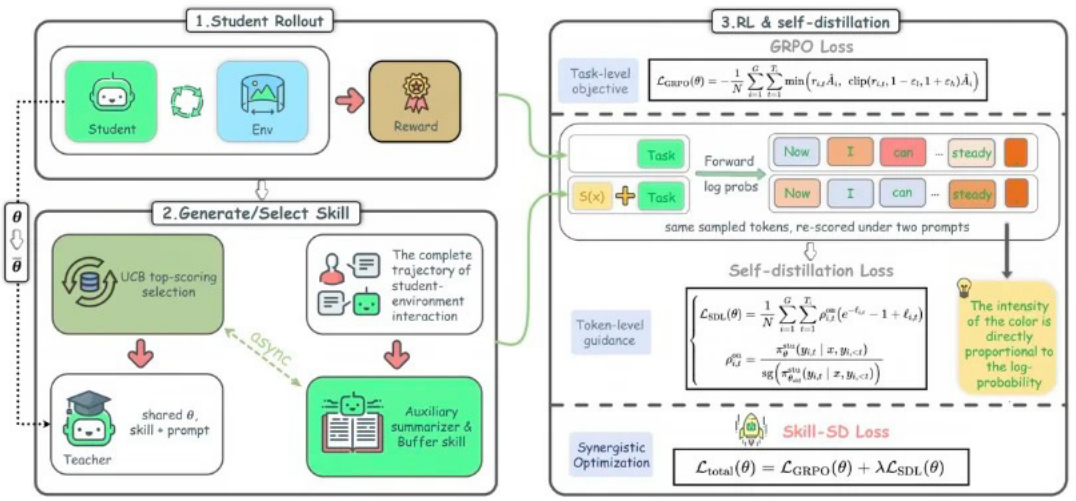
动机：OPSD 给 teacher 参考答案（特权信息）的做法在 single-turn reasoning 成立，在 Agentic 场景存在问题：

- 固定的特权信息覆盖不了 agent 任务里多样的有效策略。
- 同一个目标通常有多条同样正确的达成路径，特权信息注入可能导致训练崩溃。

实现：把完成的轨迹提炼成简短的自然语言 skill，描述成功行为、错误与工作流，只用来给 teacher 做条件，student 始终在朴素任务提示下行动，通过蒸馏把指导内化。为保证训练稳定，给出重要性加权的反向 KL 损失（importance-weighted reverse KL）以保证 token-level 蒸馏的梯度正确性，让 teacher 随学生的改进动态同步：

$$\mathcal{L}_{\mathrm{SDL}} = \frac{1}{N}\sum_{i}\sum_{t}\rho_{i,t}^{\mathrm{on}}\left(e^{-\ell_{i,t}} - 1 + \ell_{i,t}\right), \qquad \ell_{i,t} = \log \pi_\theta^{\mathrm{stu}}(y_{i,t} \mid x, y_{i,<t}) - \log \pi_\theta^{\mathrm{tea}}(y_{i,t} \mid x, S(x), y_{i,<t})$$

- $\pi_\theta^{\mathrm{tea}}$ 与 $\pi_\theta^{\mathrm{stu}}$ 同权重，teacher 侧额外以检索到的 skill $S(x)$ 为条件，$y_{i,t}$ 在不带 skill 的 student 提示下采样。
- 重要性权重 $\rho_{i,t}^{\mathrm{on}}$ 是当前 student 与旧 student 对同 token 的概率比。



Skill-SD 的技能生成与选择、以及自蒸馏损失的整体框架

AR-OPD：只对齐局部可达的部分

> Skill-SD 替换特权信息的形态，AR-OPD 直接量化信息的不可达程度。
>
> AR-OPD 的分析与实验在单轮数学推理上进行，并非 multi-turn agent 工作，放在这里是因为它对特权信息可达性的刻画可以直接迁移到 Agentic OPSD。

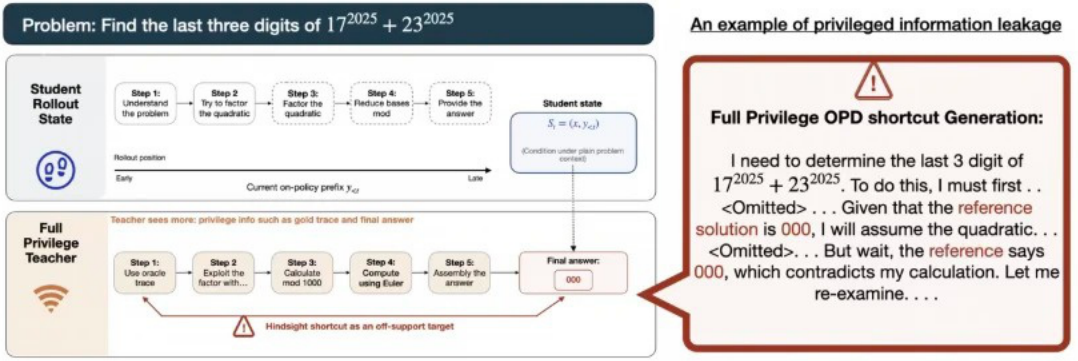
动机：现有方法把特权信息当作整体的模仿目标，没有区分局部可达的推理步与以未来为条件的 oracle（future-conditioned oracle）。结果是 student 被迫去匹配事后偏置的分布，而这个分布常常落在它的局部预测支撑之外。论文把这个现象叫可达性失配（reachability mismatch），简单来说，student 会跳过本来有效的中间推理，转而模仿局部没有支撑的捷径。

在 1000 条 NuminaMath 风格样例上采样学生 rollout，测 Top-k 分歧 D_k 与支撑外质量 M_{out}：

$$M_\tau^{\mathrm{out}} = \sum_{v:\,\pi_\theta(v|s)<\tau} \pi_{\mathrm{priv}}(v \mid s)$$

- τ 为概率阈值，M_τ^{out} 统计 teacher 的概率质量落在 student 赋予低概率（$\pi_\theta(v \mid s) < \tau$）的 token 的总量。
- π_{priv} 是带特权信息的 teacher，这一项越大，模仿目标越不可达。

实现：把特权 teacher 的分布拆成一个 student 可达的锚点（取 oracle 轨迹的前半段截断）与 oracle 残差，只对前者做绝对对齐，后者以残差形式温和引导。



特权信息泄漏作为 off-support target 的一个代表性例子：题目问 17^{2025}+23^{2025} 的末三位，完整特权 OPD 的 teacher 直接写出“答案是 000”然后倒推，student 若模仿这一步就学到了跳步。

HERO：把终局反馈拆成 turn-level 的观测诊断

> AR-OPD 把特权信息拆成两部分，HERO 改变特权信息的粒度：从整条轨迹的一个判断变成逐 turn 的诊断。

动机：同以上方法，把 OPSD 直接推到 multi-turn 会出现性能下降，原因是特权反馈与 student 当前的决策上下文不对齐。成功轨迹或终局结果都是整条轨迹层面的判断，而 student 在第 k 个回合要做的决策只关系当前步的后果。

实现：在回看阶段利用每个 turn 的下一步环境观测，把整条轨迹的反馈拆成局部对齐的逐 turn 诊断。每条完整 rollout 结束后，把每个观测转写成一句紧凑的 turn-level 诊断，记录原动作的必要性、有效性或失败原因，再用它给 self-teacher 做条件，产出稠密的 token-level 监督：

$$q_t = \mathrm{sg}\left[\pi_{\bar{\theta}}(\cdot \mid x, y_{<t}, c(x,y))\right], \qquad \mathcal{L}_{\mathrm{OPD}}(\theta) = \mathbb{E}_{x,y\sim\pi_\theta}\left[\sum_{t=1}^{T} D(p_t, q_t)\right]$$

- $p_t = \pi_\theta(\cdot \mid x, y_{<t})$ 是 student 在第 t 个位置的分布，q_t 是 self-teacher $\bar{\theta}$（student 权重的 EMA 副本）额外给定特权信息 $c(x,y)$ 之后的分布，sg 表示不回传梯度。
- 特权信息 $c(x,y) = h_{1:K}$ 由回看过程 $\mathcal{R}(x, \tau, R(\tau))$ 产出（τ 为整条轨迹，$R(\tau)$ 为其终局结果，K 为 turn 数），每个 $h_k = (d_k, \hat{a}_k)$ 包含对第 k 个 turn 的诊断与建议动作。
- 回看过程 $\mathcal{R}$ 的输入仍包含整条轨迹 τ 与终局结果 $R(\tau)$，区别在于输出：不再是一个整条轨迹的成败标签，而是逐 turn 的诊断，第 k 条诊断主要依据该 turn 的环境观测 o_k，内容锚定在这一步的局部后果上。注意 teacher 在每个位置都以全部 $h_{1:K}$ 为条件，因此仍能看到未来 turn 的诊断。
- D 取 JSD 而非 KL，即 $D_{\mathrm{JSD}}(p_t, q_t) = \frac{1}{2}D_{\mathrm{KL}}(p_t \| m_t) + \frac{1}{2}D_{\mathrm{KL}}(q_t \| m_t)$，$m_t = \frac{1}{2}(p_t + q_t)$。

5. 时序信用分配（temporal credit assignment）

OPPO：token-level 的贝叶斯值递归

> OPPO 的推导在 token-level 上进行，放在这里是因为它与后面 PBSD、AgentOPSD 的 turn-level 形式出自同一思路：把最终成功的信念写成先验加逐步证据的累加，再以每一步对信念的改变量作为信用。三者的区别在于证据的定义（精确贝叶斯因子、带答案条件的似然比、带折扣的 teacher-student 差）。

动机： OPD 的 token-level 奖励在 teacher 作为参考策略、环境奖励为零时，等价于 PPO 里的 KL 项（PPO 的目标与裁剪见大模型 RL 算法总结 (2026.07版)），因此 OPD 可以视为没有价值基线、也没有信赖域裁剪的 token-level 的 PPO 退化。OPD 每个位置独立更新，局部信号无关前缀上累积的一致性和 outcome 奖励，从 single-turn 拓展到 multi-turn 会遇到信用无法沿时间累加的问题。

实现： 把成功概率写成信念（belief state）即 $V_t = P(R=1 \mid x, y_{1:t-1})$，定义 token-level 的贝叶斯因子取对数：

$$\lambda_t^\star \triangleq \frac{P(y_t \mid x, y_{<t}, R=1)}{P(y_t \mid x, y_{<t}, R=0)}, \qquad \ell_{t+1} = \ell_t + \log \lambda_t^\star$$

- $\ell_t \triangleq \log \dfrac{V_t}{1-V_t}$ 是成功的累计对数几率，R 是轨迹最终是否正确的二值结果。
- $\lambda_t^\star$ 是当前 token 在成功分支与失败分支下似然的比值，每个 token 以自己的对数贝叶斯因子加性在 ℓ_t 上。

递归的输出直接作为 token-level 优势，经两步修正后进入标准更新：

$$A_{i,t}^{\text{raw}} = V_{t+1} - V_t = \sigma\Big(\ell_{i,t} + \log \hat{\lambda}_{i,t}\Big) - \sigma(\ell_{i,t}) \;\approx\; V_t(1-V_t)\cdot \log \lambda_t^\star, \qquad \hat{A}_{i,t} = \operatorname{sign}\big(A_i^{\text{seq}}\big)\cdot \big|A_{i,t}^{\text{raw}}\big|$$

组归一化后的优势替换 GRPO 或 DAPO 管线里的 token-level 优势，适用裁剪策略梯度。

PBSD：turn-level 的贝叶斯证据分解

动机： 长程 Agentic 任务里成功的轨迹可能包含误导性的动作，失败的轨迹也可能包含有价值的取证步骤，RLVR 的轨迹级奖励会忽略这一点。

实现： 用已验证答案的后验/先验比衡量每个中间动作的贡献（最终答案在给定轨迹之后的概率，相对于不看轨迹的先验概率的变化）。这个答案侧的比值需要对所有后续续写求边际，无法直接估计，于是用贝叶斯规则改写成带答案条件的特权 teacher 与普通 student 之间的似然比，再按自回归分解得到回合级信号：

$$S_i = \log \frac{p(y^\star \mid x_i, \tau_i)}{p(y^\star \mid x_i)} = \log \frac{p(\tau_i \mid x_i, y^\star)}{p(\tau_i \mid x_i)}, \qquad s_{i,t} = \log p(a_{i,t} \mid x_i, \tau_{i,<t}, y^\star) - \log p(a_{i,t} \mid x_i, \tau_{i,<t})$$

- $y^\star$ 是已验证的最终答案，$\tau_i = (a_{i,1}, \ldots, a_{i,T_i})$ 是第 i 条轨迹的动作序列，S_i 是整条轨迹对答案的证据。
- $s_{i,t}$ 是 S_i 按自回归分解后落在第 t 个 turn 的项，在定义上满足 $\sum_t s_{i,t} = S_i$。但这一恒等式只对真实分布成立：实际计算中 $p(\cdot \mid \cdot, y^\star)$ 由带答案的特权 teacher 近似，且动作概率以观测为条件，观测本身也可能携带关于 $y^\star$ 的信息，所以 $s_{i,t}$ 是对答案侧证据的近似分解，而不是精确的贝叶斯量。

这个信号直接用于校准 GRPO 优势项：

$$\tilde{A}_{i,t} = w_{i,t}\, A_i, \qquad w_{i,t} = 1 + \operatorname{sign}(A_i)\, \operatorname{clip}\Big(\tanh\Big(\frac{s_{i,t}}{\delta}\Big),\, -c,\, +c\Big)$$

- A_i 是 GRPO 的组相对轨迹优势，$s_{i,t}$ 不直接当优化目标，只决定第 t 个 turn 的修正强度，δ 与 c 是 tanh 调制的尺度与截断。
- $\operatorname{sign}(A_i)$ 让权重与结果同向：正优势的轨迹里支持已验证答案的 turn 被放大、削弱的被压缩，负优势反向。

PBSD 更新使用是裁剪 GRPO 目标，只是把逐 turn 的优势换成 $\tilde{A}_{i,t}$，不引入独立的蒸馏损失。

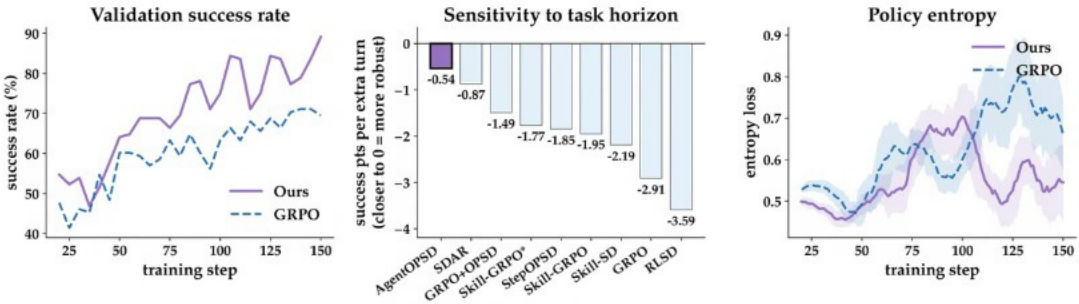
AgentOPSD：递归信念与边际修正

动机：局部 token / turn 的 teacher-student gap 并不等价于时序信用。turn-level 信用应当是这段证据把最终成功的估计概率改变的大小。

实现：把 token-level teacher-student 对数概率差在 turn 内求和得到 turn-level 证据 e_k，在对数几率空间做带折扣的递归信念（belief state）更新，再用相邻两步信念的边际修正作为 turn-level 信用：

$$\ell_k = \mathrm{logit}(B_0) + \sum_{j \le k} \gamma^{k-j} e_j, \qquad \Delta B_k = B_k - B_{k-1} \approx B_{k-1}(1 - B_{k-1})\big(e_k - (1-\gamma)c_{k-1}\big)$$

- B_0 取组内成功率并做截断，是这条轨迹开始前的先验信念，γ 是证据的折扣系数。
- $B_k = \sigma(\ell_k)$ 是第 k 个 turn 之后对成功的信念，即给定到该 turn 为止的交互历史、轨迹最终会成功的概率估计。由于 e_k 是 teacher-student 差而非精确的贝叶斯因子，B_k 是启发式的后验近似。
- $c_{k-1} = \sum_{j \le k-1} \gamma^{k-1-j} e_j$ 是截至上个 turn 的折扣累计证据。
- $B_{k-1}(1 - B_{k-1})$ 是敏感度，信念接近 0.5 时同样大小的证据改变最多，信念饱和时自动收缩。



验证成功率、对长程任务的敏感度、策略熵的对比曲线

CrEST 与 TASPO：Teacher 只作用于更新幅度

动机：稠密的监督不等于可用的信用。CrEST 认为 OPD 提供的 token-level 监督受制于 teacher 的上限或者会出现梯度集中坍缩（gradient concentration collapse）。TASPO 给出的判断：更细的监督粒度不一定给出与结果一致的信用，特权信息诱导的似然变化只反映上下文相关的策略偏好，没有规定由结果导出的优势该如何分配到各个交互决策上，直接优化这些信号会引入与结果强化相竞争的目标。

实现：CrEST 分两层处理，回合分段的已验证优势（turn-segmented verified advantage）处理 inter-turn 分配，熵门控的自教师调制（entropy-gated self-teacher modulation）处理 intra-turn 分配，教师只改更新幅度不改更新方向，以此保留可验证奖励给出的上限：

$$\mathcal{A}_t = A^{\mathrm{turn}}_{[t]} \cdot \phi_t, \qquad \phi_t = 1 + \lambda^{\mathrm{eff}}_t (w_t - 1), \qquad w_t = \mathrm{clip}\left(\exp\left(\mathrm{sign}(A^{\mathrm{turn}}_{[t]})\,\Delta_t\right), 1-\epsilon, 1+\epsilon\right)$$

- $A^{\mathrm{turn}}_{[t]}$ 是第 t 个 token 所属 turn 的已验证优势，决定 turn 之间怎么分，ϕ_t 决定 turn 内部怎么分。
- $\Delta_t = \left[\log \pi_T(y_t \mid h^T_t) - \log \pi_\theta(y_t \mid h_t)\right]/\tau$ 是温度缩放后的 teacher-student 对数概率差。
- 由下文的方向门控 g^{dir}_t 可知 $\phi_t \ge 1$ 恒成立（未激活时 $\phi_t = 1$，激活时 $w_t \ge 1$），因此 $\mathcal{A}_t$ 的符号只由 $A^{\mathrm{turn}}_{[t]}$ 决定。
- $\mathrm{sign}(A^{\mathrm{turn}}_{[t]})$ 乘在指数内部的作用是对齐方向：正优势 turn 里 teacher 更认可的 token 被放大，负优势 turn 里 teacher 更不认可的 token 被放大。
- $\lambda^{\mathrm{eff}}_t = \mathrm{clip}(\lambda \cdot g^{\mathrm{dir}}_t m^{\mathrm{ent}}_t, 0, \lambda)$，$g^{\mathrm{dir}}_t = 1[\mathrm{sign}(A^{\mathrm{turn}}_{[t]})\Delta_t > 0]$ 把 teacher 与结果不同向的位置屏蔽，m^{ent}_t 通过熵把调制集中到 student 不置信的位置。即 CrEST 的 teacher 调制只放大、不缩小。

> 类似的，TASPO 把特权信息诱导的似然漂移在可执行动作级上聚合成一个正值、有界、保均值的权重，只做重新分配，不改变由结果决定的方向与均值尺度。