Agentic OPD：从三个失效假设出发

Single-turn token distillation 的默认前提，在 multi-turn environment interaction 中同时破裂

三个失效假设

Problem formulation

Agentic On-Policy Distillation: A Comprehensive Survey

Single-turn OPD 通常把 Student rollout prefix 视为固定输入，在每个 token 上匹配 Teacher distribution。进入 Agent 场景后，action 会改变 observation、memory 和后续可达状态，因此局部 KL 不再自动等价于正确的长程 credit。

- 假设 1：监督单位与 credit 单位一致。Agent turn 同时包含 reasoning、tool arguments 和非决策 observation tokens。
- 假设 2：Teacher 在 Student 到达的状态上仍然可靠。错误 tool call 会把轨迹推入 Teacher 很少见的状态。
- 假设 3：Teacher–Student likelihood ratio 可以直接充当 value/advantage。它首先衡量 imitation gap，不保证与任务结果因果一致。

$$\mathcal{L}_{\mathrm{OPD}} = \mathbb{E}_{y\sim\pi_\theta} \sum_t D_{\mathrm{KL}}(\pi_\theta(\cdot \mid y_{1:t-1}) \,\|\, \pi_T(\cdot \mid y_{1:t-1}, c))$$

Primary source: 2604.00626v5 · official paper figure and equations

四条研究主线

Roadmap

从 supervision granularity 到 temporal credit assignment

2026 年的 Agentic OPD 工作并不是沿一条线演进，而是在四个相互耦合的问题上同时推进。

- 监督与 credit 粒度：SOD、StepOPSD、TurnOPD。
- Covariate shift 与状态覆盖：Revisiting DAgger、Guided-OPD、SAGE-OPD、ReOPD。
- Privileged information asymmetry：Skill-SD、AR-OPD、HINT。
- Temporal credit assignment：OPPO、PBSD、AgentOPSD、CrEST、TASPO。

$$\textbf{local matching} \neq \textbf{credit for reaching the matched state}$$

Primary source: 2604.00626v5 · official paper figure and equations

读图方式：后续方法分别回答“监督是否可信、状态如何覆盖、Teacher 知道什么、结果如何回传”。

为什么需要 Agentic OPD?

从整段 token matching，走向错误传播下的 step-wise reliability

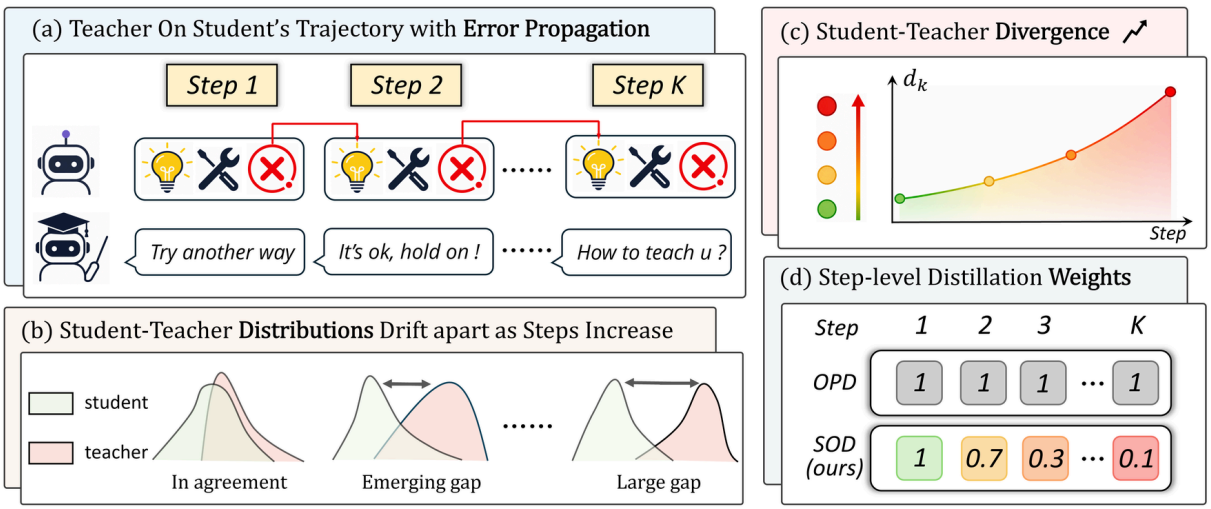
SOD

Step reliability

Step-wise On-policy Distillation for Small Language Model Agents

多轮工具交互中，一个错误 action 会注入大段异常 observation。后续状态逐步离开 Teacher support，统一累加 OPD loss 会把高方差监督当成同等可靠。

- 按模型生成步骤聚合 Student−Teacher log-prob gap，而不是把整条 trajectory 视作同质 token 流。
- 前一步分歧变大时降低当前 step 权重；策略恢复时允许权重回升，并限制最大放大幅度。
- I_k 是第 k 个生成步骤的 token 集合；论文使用 $\varepsilon=10^{-6}$ 稳定比值，并以 δ 限制最大放大幅度。
- 核心贡献是 reliability weighting；它仍以 disagreement 作为 proxy，不等价于真实因果责任。



$$\Delta_k = \frac{1}{|\mathcal{I}_k|} \sum_{t \in \mathcal{I}_k} D_{\mathrm{KL}}(\pi_\theta(\cdot \mid y_{1:t-1}) \,\|\, \pi_T(\cdot \mid y_{1:t-1}))$$

$$d_k = \frac{1}{|\mathcal{I}_k|} \sum_{t \in \mathcal{I}_k} |\log \pi_\theta(y_t \mid y_{1:t-1}) - \log \pi_{\text{teacher}}(y_t \mid y_{1:t-1})|$$

$$w_k = \min\left(w_1 \prod_{u=1}^{k-1} \frac{d_u + \epsilon}{d_{u+1} + \epsilon}, 1 + \delta \right)$$

Primary source: 2605.07725v3 · official paper figure and equations

Agentic OPD 的第一条主线：先判断当前 step 的 Teacher signal 是否还可信。

把 Hindsight 变成 Step-level Credit

StepOPSD：不改变在线 rollout，只在事后重塑 advantage

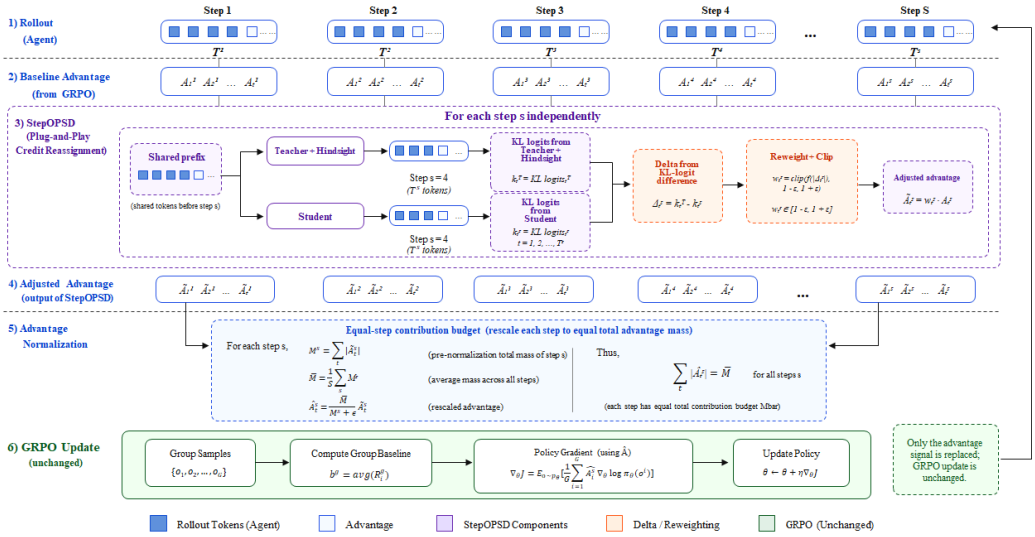
StepOPSD

Hindsight shaping

Step-Aware Online Preference Self-Distillation for Agent Reinforcement Learning

Student 仍按原策略与环境交互；rollout 完成后，将轨迹切成 causal action spans，并在加入 hindsight 的 Teacher context 下重评分同一 token。

- Teacher−Student likelihood gap 提供 dense token preference，但不替换环境给出的 outcome advantage。
- 用 advantage 符号决定 gap 的方向，再经过 sigmoid 与 clip 得到有界 credit weight。
- 每个 step 单独归一化到相同 contribution budget，避免长 action 因 token 更多而占据更大梯度。
- 最终只调节 GRPO advantage 的幅度，保留原始 outcome 的正负方向；GRPO update 本身不变。



$$\Delta_{k,j} = \log \pi_T(z_{k,j} \mid c_k^T, z_{k,1:j-1}) - \log \pi_S(z_{k,j} \mid c_k^S, z_{k,1:j-1})$$

$$w_\ell = \Pi_{[1-\alpha_{\text{clip}},\, 1+\alpha_{\text{clip}}]}(2\sigma(\text{sign}(A_\ell)\Delta_\ell))$$

$$\widetilde{A}_\ell = (1-\lambda_{\text{mix}})A_\ell + \lambda_{\text{mix}}(w_\ell A_\ell)$$

Primary source: 2605.27140v2 · official paper figure and equations

变化：Teacher 不再只提供 imitation target，而开始参与 outcome credit 的局部再分配。

让 OPD 感知 Turn 与 Horizon

TurnOPD：训练多深、每个 turn 占多大权重，都由在线统计控制

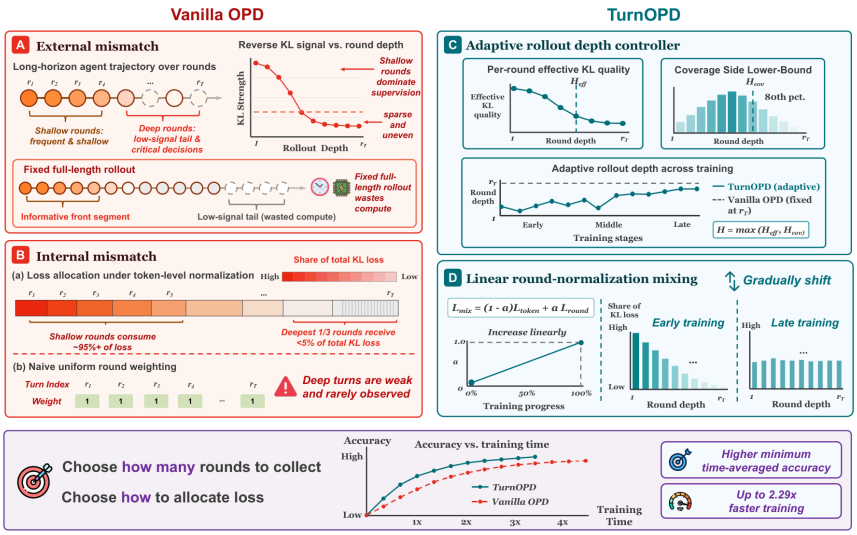
TurnOPD

Turn-aware horizon

Making On-Policy Distillation Turn-Aware for Efficient Long-Horizon Agent Training

Vanilla OPD 在长 horizon 中出现外部错配与内部错配：Teacher uncertainty 和 reverse-KL 随 turn 加深，深层 token 又可能在 trajectory normalization 下占据过多 loss。

- 用每 turn KL 与 survivor ratio 估计有效 rollout 深度。
- 再用成功轨迹长度分位数给出 coverage lower bound，避免 horizon 过短。
- 从 token/trajectory-normalized loss 线性切换到 turn-normalized loss，减少长 turn 对梯度的垄断。
- 论文同时优化收集多少 rounds 与如何分配 loss，并报告最高约 2.29× 的训练加速。



$$H_{\text{ctrl}} = \max(H_{\text{eff}}, H_{\text{cov}})$$

$$\mathcal{L}_{\text{mix}} = (1-\alpha)\mathcal{L}_{\text{token}} + \alpha\mathcal{L}_{\text{round}}$$

$$q_t^{\text{blend}} = (1-\alpha)\frac{n_t}{\sum_j n_j} + \alpha\frac{1}{T}, \qquad H_{\text{cov}} = Q^p(L_{\text{succ}})$$

Primary source: 2607.05804v2 · official paper figure and equations

Agentic OPD 的第二条主线：监督不仅要可信，还要控制暴露到多深的状态分布。

控制 Student 访问的状态分布

从 DAgger 的 Teacher mixing，到 Guided-OPD 的 curriculum turn guidance

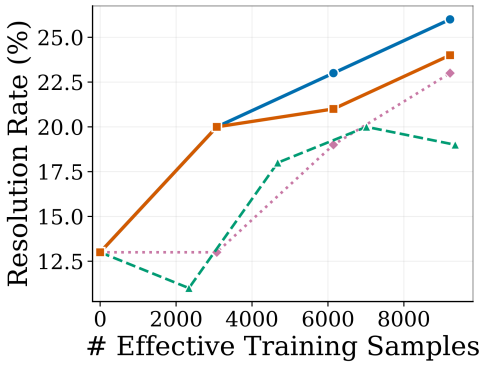
Revisiting DAgger

Mixed-policy rollout

Revisiting DAgger in the Era of LLM-Agents

仅在 Teacher demonstrations 上 SFT 会遭遇 covariate shift；纯 Student rollout 又会在冷启动时迅速进入无效状态。DAgger 在每个 turn 随机选择 Teacher 或 Student，并收集 Teacher labels。

- 逐 turn mixture 扩大可恢复状态覆盖；β_i 随训练逐渐衰减到 0。
- 另一种 prefix mixing 在选定切点后由 Teacher 接管后续 turns。
- 聚合数据集上的训练目标仍是 Teacher action 的交叉熵。



$$\mu_i = \beta_i \pi_e + (1-\beta_i)\pi_{\theta_i}$$

$$p_i^{\text{turn}}(b_{1:T}) = \prod_{t=1}^{T} \beta_i^{b_t}(1-\beta_i)^{1-b_t}$$

Primary source: 2605.12913v1 · official paper figure and equations

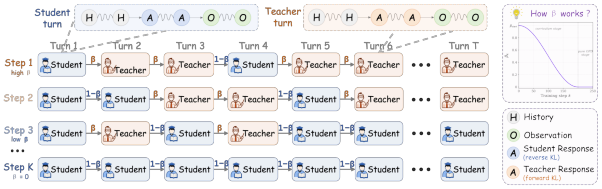
Guided-OPD

Curriculum mixing

On-Policy Distillation with Curriculum Turn-level Guidance for Multi-turn Agents

Guided-OPD 将 DAgger 式混合嵌入 OPD：训练早期 Teacher turns 较多，随后按 curriculum 衰减到纯 Student on-policy rollout。

- Teacher turn 使用 forward-KL；Student turn 使用 reverse-KL。
- Early guidance 把轨迹锚定在 Teacher 熟悉区域，随后逐步增加 Student turns。
- 最终阶段 β=0，与标准 OPD 一致。



$$a_t \sim \pi_\theta(\cdot \mid h_t)\,[1-\beta_t], \qquad a_t \sim \pi_\phi(\cdot \mid h_t)\,[\beta_t]$$

$$\beta_t = \beta_{\text{start}} + (\beta_{\text{end}} - \beta_{\text{start}})\frac{1-\cos(\pi\xi_t)}{2}$$

$$\mathcal{L}_t = (1-\beta_t)\mathcal{J}_{\text{rKL}}^{\pi_\theta} + \beta_t \mathcal{J}_{\text{fKL}}^{\pi_\phi}$$

Primary source: 2606.15912v3 · official paper figure and equations

关键取舍：Teacher intervention 改善状态覆盖，但 intervention 后的 history 不再是纯 Student on-policy。

选择性干预与 Offline Prefix Replay

不必在每个 turn 都调用 Teacher，也不必让环境在训练全程保持在线

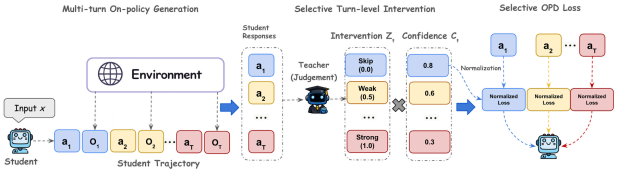
SAGE-OPD

Selective intervention

Selective Agent-Guided Intervention for Multi-Turn On-Policy Distillation

Intervention Agent 依据 Student response、Teacher disagreement 与 confidence，在 Skip / Weak / Strong 三档之间选择。

- Intervention intensity 为 0 / α / 1，分别对应 Skip / Weak / Strong。
- Teacher confidence 沿 Student action prefix 聚合，抑制低置信 Teacher 的干预。
- 按实际被监督 token 数归一化，保持 loss scale 稳定。



$$c_t = \frac{1}{|a_t|}\sum_{i=1}^{|a_t|}\max_{v\in\mathcal{V}}\pi_\phi(v \mid h_t, a_{t,1:i-1})$$

$$i_t \in \{0,\alpha,1\}, \qquad s_t = i_t c_t$$

$$\mathcal{L}_{\text{SAGE}} = Z\sum_t s_t \mathcal{L}_{\text{OPD}}(h_t, a_t)$$

Primary source: 2606.19659v1 · official paper figure and equations

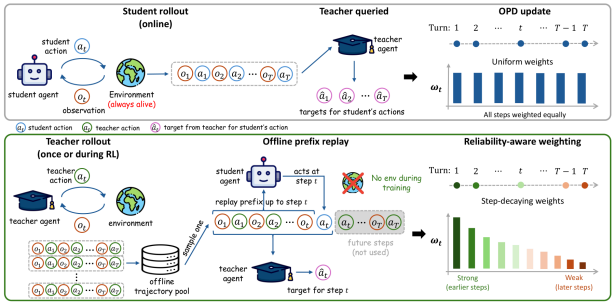
ReOPD

Offline replay

Multi-Turn On-Policy Distillation with Prefix Replay

Teacher trajectories 只需离线收集一次；Student training 通过 prefix replay 构造状态，环境无需始终在线，并让较早 step 获得更高权重。

- 用 Student / Teacher occupancy 的 geometric bridge 控制 replay distribution。
- γ_t 平衡 Student occupancy mismatch 与 Teacher prefix reliability，避免 prefix trap。
- Teacher-prefix 与 Student-prefix 样本分别用相反方向的 density ratio 校正；指数衰减近似长期 cost。



$$\rho_t^\star(h_t \mid x) \propto [d_t^{\theta_{\text{old}}}(h_t \mid x)]^{\gamma_t}[d_t^T(h_t \mid x)]^{1-\gamma_t}$$

$$\gamma_t = \frac{\lambda_{\text{stu},t}}{\lambda_{\text{stu},t}+\lambda_{\text{tea},t}}, \quad w_t^T \propto \left(\frac{d_{\text{old}}^t}{d_T^t}\right)^{\gamma_t}$$

$$\omega(t,\kappa) = \kappa^t$$

Primary source: 2607.04763v3 · official paper figure and equations

这一阶段开始同时优化监督质量、Teacher query 成本与 environment availability。

动态 Teacher 信息：从固定答案到 Skill

Skill-SD：Teacher privilege 来自 trajectory analysis，而不是唯一标准路径

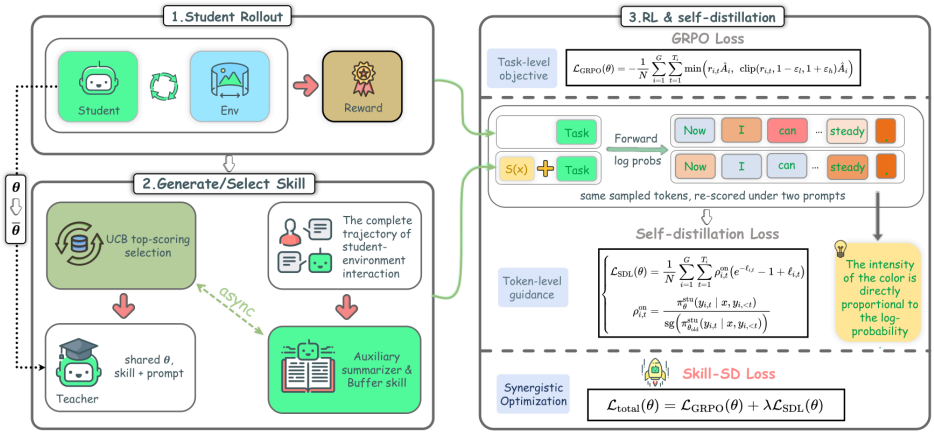
Skill-SD

Dynamic privileged context

Skill-Conditioned Self-Distillation for Multi-turn LLM Agents

Agent task 往往存在多条有效 action path。Skill-SD 将完成轨迹异步总结为 success analysis、mistake analysis 与 golden workflow，并存入 UCB-indexed skill buffer。

- Student 使用原始 prompt；Teacher 在同一 token prefix 上额外读取检索到的 skills。
- GRPO 提供 task-level credit；importance-weighted SDL 迁移 token-level Teacher distribution。
- Skill 由异步 summarizer 生成，并通过 UCB top-scoring buffer 在探索新技能与复用高价值技能之间平衡。
- 动态 Skill 解决 Teacher 应该知道什么，但不直接解决后续 outcome 对早期 action 的因果归因。



$$e = \mathbf{Analyze}(\tau, x) = (e_{\mathbf{success}}, e_{\mathbf{mistake}}, e_{\mathbf{workflow}})$$

$$\ell_{i,t} = \log \pi_\theta^{\mathrm{stu}}(y_{i,t} \mid x, y_{i,1:t-1}) - \log \pi_{\bar{\theta}}^{\mathrm{tea}}(y_{i,t} \mid x, S(x), y_{i,1:t-1})$$

$$\mathcal{L}_{\mathrm{SDL}} = \frac{1}{N} \sum_{i,t} \rho_{i,t}^{\mathrm{on}} \left(e^{-\ell_{i,t}} - 1 + \ell_{i,t} \right)$$

$$\mathcal{L}_{\mathrm{total}} = \mathcal{L}_{\mathrm{GRPO}} + \lambda \mathcal{L}_{\mathrm{SDL}}$$

Primary source: 2604.10674v1 · official paper figure and equations

Agentic OPD 的第三条主线：privileged information 从静态 oracle 走向随经验演化的可检索技能。

信息不对称：Privileged Teacher 也可能误导

AR-OPD 校准 support mismatch；HINT 把 hindsight 压缩到真正的 decision fork

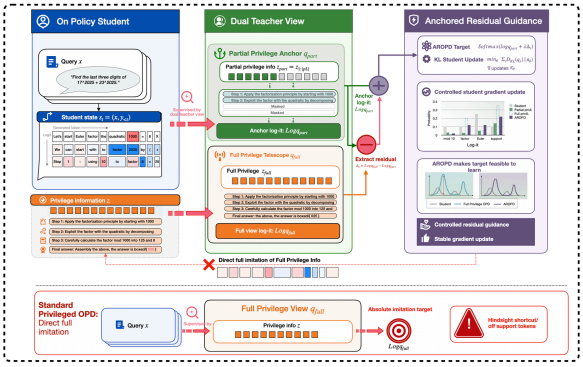
AR-OPD

Anchored residual

Beyond Absolute Imitation: Anchored Residual Guidance for Privileged On-Policy Distillation

Full privileged context 可能让 Teacher 依赖 Student 永远看不到的答案状态。AR-OPD 先构造 partial anchor，再只迁移 full view 相对 anchor 的 residual。

- Anchor 保留可由 Student 重建的支持。
- M_out 衡量 privileged Teacher 落到 Student 低支持 token 上的概率质量。
- λ 控制 privileged residual 强度，避免把 oracle shortcut 当作绝对模仿目标。



$$M_\tau^{\text{out}} = \sum_{v:\, \pi_{\text{stu}}(v|s) \le \tau} \pi_{\text{priv}}(v \mid s)$$

$$\log q_\lambda = \log q_{\text{part}} + \lambda(\log q_{\text{full}} - \log q_{\text{part}}) - C_t$$

Primary source: 2606.10385v1 · official paper figure and equations

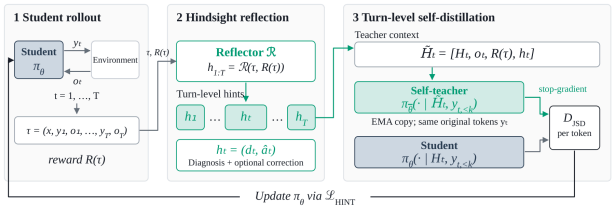
HINT

Compressed hindsight

Multi-Turn Agent Self-Distillation with Compressed Hindsight

Reflector 将完整 trajectory outcome 压缩为 turn-level diagnosis 与可选纠正动作，只在识别出的错误 turns 蒸馏。原始长图写作 HERO，但对应论文和方法实际为 HINT。

- Teacher context 注入 diagnosis，而不是泄露完整参考答案。
- Reflector 将终局反馈拆成每个错误 turn 的 diagnosis 与可选纠正 action。
- 使用对称、有界的 JSD，并只在识别出的错误 turns 上聚合。



$$h_t = (d_t, \hat{a}^t), \qquad q_t = \text{sg}[\pi_{\bar{\theta}}(\cdot \mid x, y_{1:t-1}, h_t)]$$

$$D_{\text{JSD}}(p_t, q_t) = \tfrac{1}{2} D_{\text{KL}}(p_t \| m_t) + \tfrac{1}{2} D_{\text{KL}}(q_t \| m_t)$$

$$\mathcal{L}_{\text{HINT}} = \frac{1}{|I(\tau)|} \sum_{t \in I(\tau)} \ell_t$$

Primary source: 2606.11559v2 · official paper figure and equations

新问题：Teacher 拥有更多信息不代表它在 Student state 上一定校准良好。

Bayesian Credit：从证据增量到 Turn Advantage

OPPO 给出 token-level value recursion；PBSD 将 privileged evidence 引入长程 Agent

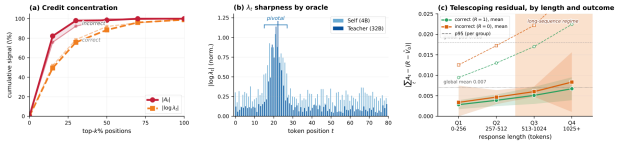
OPPO

Token Bayesian evidence

Bayesian Value Recursion for Token-Level Credit Assignment in LLM Reasoning

把每个 token 的 likelihood ratio 视为 Bayesian evidence，递归更新成功概率；相邻 value 的变化就是局部 advantage。

- λ_t* 是成功条件与失败条件下当前 token likelihood 的 Bayes factor。
- Token advantages telescoping 到最终 reward 与初始 value 的差。
- 一阶近似把 credit 分解为 uncertainty × evidence，并用 sequence outcome 符号校准方向。



$$V_t = P(R=1 \mid x, y_{1:t-1}), \qquad \lambda_t^\star = \frac{P(y_t \mid x, y_{1:t-1}, R=1)}{P(y_t \mid x, y_{1:t-1}, R=0)}$$

$$V_{t+1} = \frac{\lambda_t^\star V_t}{\lambda_t^\star V_t + (1 - V_t)}, \qquad A_t^{\text{raw}} = V_{t+1} - V_t$$

$$\widehat{A}_{i,t} = \text{sign}(A_i^{\text{seq}}) |A_{i,t}^{\text{raw}}|, \qquad \sum_t A_t = R - V_0$$

Primary source: 2605.21851v2 · official paper figure and equations

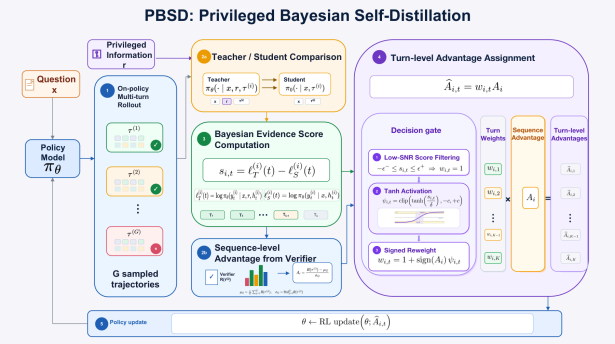
PBSD

Turn Bayesian evidence

Privileged Bayesian Self-Distillation for Long-Horizon Credit Assignment

比较有/无 privileged outcome information 时当前 action 的 likelihood，得到 turn-level evidence score，再通过 decision gate 调整 sequence advantage。

- Bayes identity 将 outcome posterior 转换为 trajectory evidence ratio，并分解为 turn evidence。
- 成功轨迹可能含坏动作、失败轨迹也可能含好动作；binary reward 无法表达这种局部差异。
- 有界 tanh 权重保留 sequence reward 的方向，同时在 turn 内重新分配幅度。



$$S_i = \log \frac{p(y^\star \mid x_i, \tau_i)}{p(y^\star \mid x_i)} = \sum_t s_{i,t}$$

$$s_{i,t} = \log p(a_{i,t} \mid x_i, \tau_{i,1:t-1}, y^\star) - \log p(a_{i,t} \mid x_i, \tau_{i,1:t-1})$$

$$\tilde{A}_{i,t} = w_{i,t} A_i, \quad w_{i,t} = 1 + \text{sign}(A_i)\text{clip}\left(\tanh \frac{s_{i,t}}{\delta}, -c, c\right)$$

Primary source: 2606.09348v2 · official paper figure and equations

Bayesian 视角把 Teacher gap 从“模仿误差”改写成“当前动作对成功结论提供了多少证据”。

递归与层级 Credit Assignment

AgentOPSD 用 belief revision 分 turn；CrEST 让 verifier 决定方向、Teacher 只教幅度

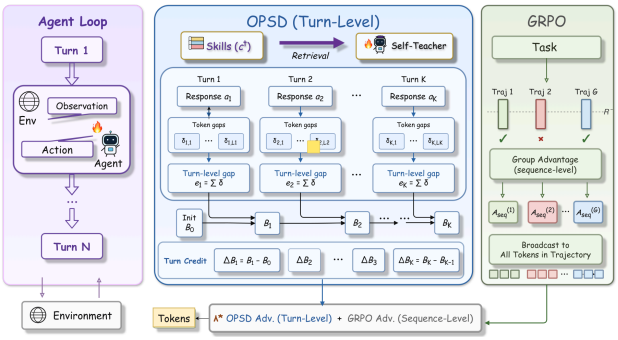
AgentOPSD

Recursive belief

Recursive Self-Distillation for Agentic Reinforcement Learning

先将 token-level privileged gap 聚合为 turn evidence，再递归更新成功 belief。相邻 belief revision 作为每个 turn 的局部 credit。

- 初始 belief B_0 来自 clipped group success rate。
- γ 对历史 evidence 做递归折扣，避免早期信号永久主导。
- belief sensitivity B(1−B) 在模型最不确定时放大证据，最终 credit 与 sequence outcome 符号对齐。



$$e_k = \log \frac{\pi_\theta(a_k \mid s_k, c^+)}{\pi_\theta(a_k \mid s_k)}, \qquad c_k = \gamma c_{k-1} + e_k$$

$$\ell_k = \mathrm{logit}(B_0) + c_k, \qquad B_k = \sigma(\ell_k)$$

$$\Delta B_k \approx B_{k-1}(1 - B_{k-1})\,(e_k - (1-\gamma)c_{k-1})$$

Primary source: 2608.05987v1 · official paper figure and equations

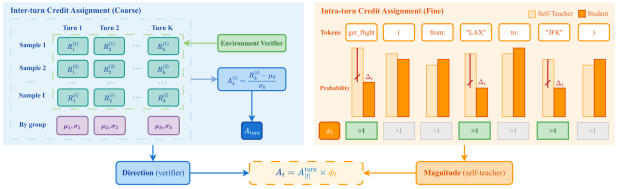
CrEST

Verifier-anchored hierarchy

Teach the Magnitude, Not the Direction

Teacher disagreement 不应决定更新方向。CrEST 让 environment verifier 提供 turn-level sign，self-teacher 只调节 token-level magnitude。

- Inter-turn credit 的方向来自 environment verifier。
- Intra-turn magnitude 由 entropy-gated Teacher gap 提供。
- 只有 Teacher preference 与 verifier direction 一致时才开启 modulation，并通过 clip 防止梯度集中。



$$\mathcal{A}_t = A^{\mathrm{turn}}_{[t]}\phi_t, \qquad \phi_t = 1 + \lambda^{\mathrm{eff}}_t(w_t - 1)$$

$$w_t = \mathrm{clip}\Big(\exp(\mathrm{sign}(A^{\mathrm{turn}}_{[t]})\Delta_t), 1-\epsilon, 1+\epsilon\Big)$$

$$\lambda^{\mathrm{eff}}_t = \mathrm{clip}(\lambda g^{\mathrm{dir}}_t m^{\mathrm{ent}}_t, 0, \lambda)$$

Primary source: 2608.13179v2 · official paper figure and equations

方向与幅度解耦，是减少 privileged Teacher 误导风险的一条清晰设计原则。

TASPO：Outcome-Constrained Process Supervision

用 verified successful siblings 构造 trajectory-aligned PI，同时守住 outcome advantage

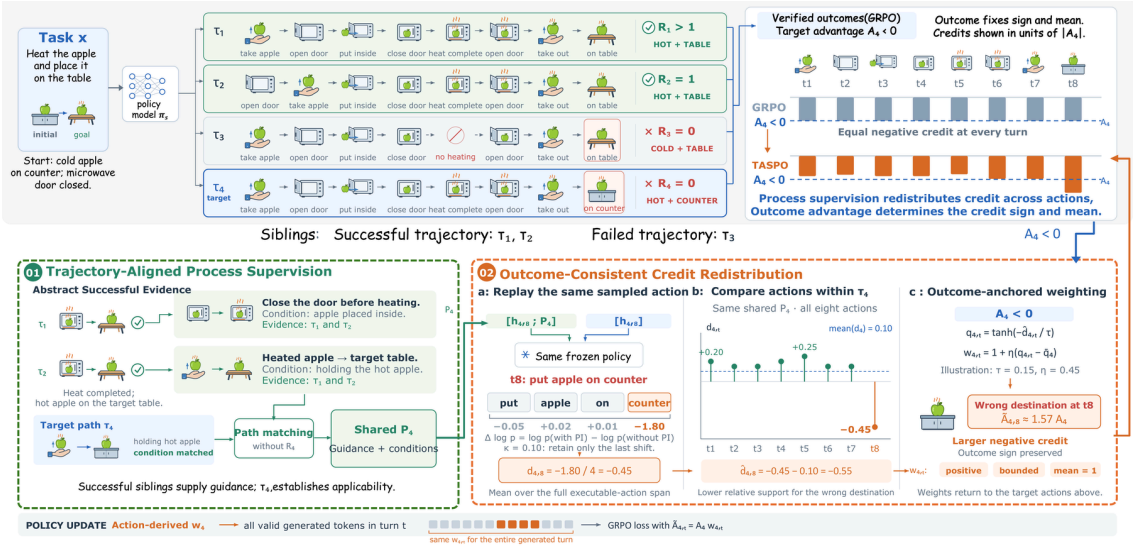
TASPO

Outcome-constrained redistribution

Reconciling Process Supervision with Outcome-Based Credit in Agentic Policy Optimization

TASPO 从同任务的 verified successful siblings 提取与当前 trajectory 对齐的 privileged information，在 action level 计算 likelihood shift，并把它转换为有界、均值为 1 的 advantage weights。

- 权重始终为正，不翻转 outcome advantage 的符号。
- 每条 trajectory 上权重均值为 1，不改变总体 advantage budget。
- 局部 process supervision 只重新分配 credit，不覆盖 verifier 给出的成败结论。



$$\tilde{A}_t^i = A_i w_t^i, \qquad 1-\epsilon_w \le w_t^i \le 1+\epsilon_w, \qquad \frac{1}{T_i}\sum_t w_t^i = 1$$

$$\Delta_{t,k}^i = \mathrm{sg}[\log \pi_{\theta_{\text{old}}}(y_{t,k}^i \mid P_i, h_t^i, y_{t,1:k-1}^i) - \log \pi_{\theta_{\text{old}}}(y_{t,k}^i \mid h_t^i, y_{t,1:k-1}^i)]$$

$$q_t^i = \tanh\left(\frac{\mathrm{sign}(A_i)\bar{d}_t^i}{\tau}\right)$$

$$w_t^i = 1 + \eta(q_t^i - \bar{q}_i)$$

Primary source: 2608.31077v2 · official paper figure and equations

发展脉络：局部 KL → step reliability → state coverage → dynamic PI → Bayesian/recursive credit → outcome-constrained redistribution。